C01 — Problema de pesquisa, escopo e hipóteses

EduPredict Analytics (EPA) · Cadernos de Pesquisa · TGI II

Carlos Eduardo Franco Gabriel · Miguel Ferreira Palmieri Souza Rocha

Universidade Cruzeiro do Sul — Ciência da Computação — São Paulo, Brasil

Orientador: Prof. Me. João Roberto Ursino da Cruz

Versão: 0.3 (congelamento sintético de 12 nov. 2026)

Status: SYNTHETIC_NOT_EMPIRICALLY_VALIDATED

Resumo. Definir a tarefa supervisionada, a unidade observacional e os limites de inferência do EduPredict Analytics. O documento distingue resultados medidos, explicação técnica e inferências limitadas à população sintética GENESIS.

Palavras-chave. EduPredict Analytics; avaliação temporal; dados sintéticos; rastreabilidade; aprendizado de máquina.

1. Contexto e motivação

A disponibilidade de notas, presenças e informações históricas não significa que uma escola possua um mecanismo validado de intervenção. O EduPredict Analytics (EPA) propõe uma infraestrutura de pesquisa que transforma registros acadêmicos em instantâneos temporais, compara algoritmos e conserva evidências verificáveis. O objetivo deste caderno é declarar o problema e seus limites antes de interpretar qualquer percentual de acerto.

A pergunta investigada nesta fase é: **em condições sintéticas controladas, qual desempenho classificatório é obtido para o resultado final da disciplina quando somente registros disponíveis até N1, N2 ou N3 são fornecidos?** A pergunta **não** é se o sistema prevê evasão escolar com confiabilidade real.

2. Tarefa e unidade de análise

A variável-alvo possui três classes mutuamente exclusivas: **aprovado**, **recuperação** e **reprovado**. Cada observação corresponde a um contexto de matrícula/ano e disciplina, avaliado em determinado corte. Um estudante pode, portanto, originar muitas observações; elas não constituem indivíduos estatísticos independentes.

O alvo é o desfecho da disciplina. Retenção escolar, evasão, transferência, abandono e permanência são fenômenos distintos que exigiriam rótulos e observações específicos. Utilizar o termo «risco de evasão» para essas predições seria uma extrapolação não sustentada.

3. Hipóteses operacionais

H1 (antecedência): ao avançar de N1 para N3, o modelo incorpora mais evidências e melhora a classificação no mesmo processo gerador sintético. **H2 (parcimônia):** um classificador linear pode atingir desempenho próximo ao de uma rede multicamadas. **H3 (robustez local):** o desempenho se mantém relativamente estável quando o subconjunto selecionado cresce de 500 para 5.000 estudantes, dentro da mesma população geradora.

Essas hipóteses são examinadas com **macro-F1**, acurácia, recall por classe, log loss, Brier e tempo de ajuste. A comparação de modelos usa separação agrupada por estudante e diferenças pareadas calculadas com as mesmas observações de teste.

4. Contribuição e fronteiras

O estudo combina engenharia de dados sintéticos, contratos temporais verificáveis, avaliação por cortes, estimadores e ferramentas de diagnóstico probabilístico. A contribuição científica é metodológica e computacional: **demonstração reprodutível dentro de um ambiente simulado**; não comprovação de eficácia operacional em uma escola.

5. Leitura preliminar do resultado

No teste 5K, o macro-F1 da Regressão Logística passou de 0,7540 (N1) para 0,8934 (N3). Para o MLP passou de 0,7578 a 0,8933. Os valores são médias descritivas de três holdouts sobre a mesma população sintética, não replicações populacionais independentes.

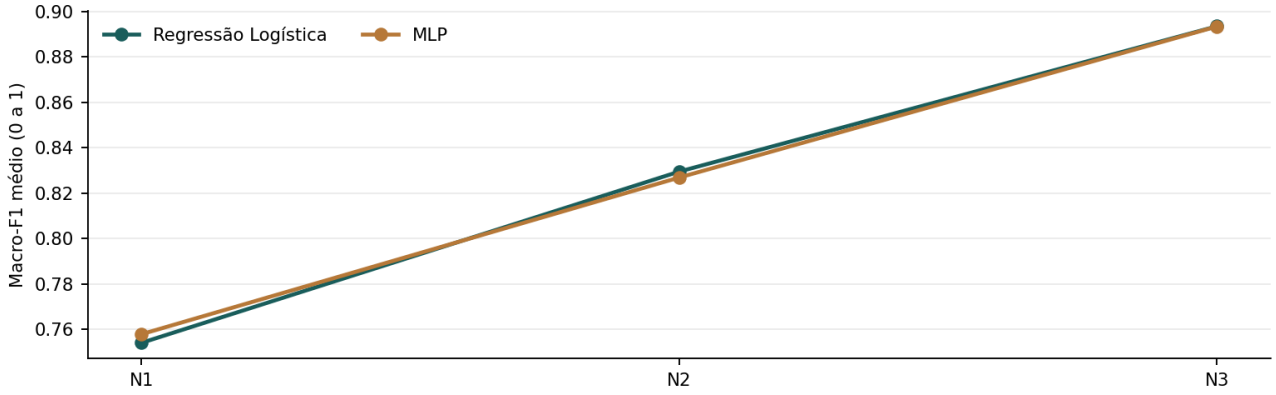


Figura 1. Macro-F1 médio por corte.
Fonte: elaboração própria, com base no relatório sintético MAPA 5K (schema epa.mapa.statistical_evaluation.v1).

6. Vocabulário em formação

Classificação multiclasse: atribuição de uma entre três classes. **Alvo (target):** resultado a prever. **Feature:** atributo utilizado como entrada. **Holdout:** separação de dados para avaliar um modelo fora de sua amostra de ajuste. **Macro-F1:** média não ponderada do F1 das classes; evita privilegiar somente a classe abundante.

7. Síntese crítica

A viabilidade observada é limitada ao ecossistema sintético sob contrato. A conclusão do artigo deverá separar o que o sistema executou do que ainda depende de dados reais, estudo longitudinal independente e avaliação de utilidade pedagógica.

Referências e rastreabilidade

[1] Gneiting, T.; Raftery, A. E. (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, 102(477), 359–378. DOI: 10.1198/016214506000001437. [2] Efron, B.; Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman & Hall. [3] scikit-learn developers. User Guide: Model evaluation, Probability calibration, GroupShuffleSplit, MLPClassifier. https://scikit-learn.org/stable/user_guide.html (consulta metodológica; versão efetiva do ambiente deve ser registrada). [4] EduPredict Analytics. Relatório técnico interno MAPA 5K, schema epa.mapa.statistical_evaluation.v1; manifesto ec863d9f267564e27adf1a701f88951cf064af744eb2452708f120c22d947f23; população sintética e três seeds, novembro de 2026.