C02 — GENESIS Rust e proveniência longitudinal

EduPredict Analytics (EPA) · Cadernos de Pesquisa · TGI II

Carlos Eduardo Franco Gabriel · Miguel Ferreira Palmieri Souza Rocha

Universidade Cruzeiro do Sul — Ciência da Computação — São Paulo, Brasil

Orientador: Prof. Me. João Roberto Ursino da Cruz

Versão: 0.3 (congelamento sintético de 12 nov. 2026)

Status: SYNTHETIC_NOT_EMPIRICALLY_VALIDATED

Resumo. Explicar o papel do gerador sintético e a rastreabilidade necessária para reprodução sem confundir simulação com evidência empírica. O documento distingue resultados medidos, explicação técnica e inferências limitadas à população sintética GENESIS.

Palavras-chave. EduPredict Analytics; avaliação temporal; dados sintéticos; rastreabilidade; aprendizado de máquina.

1. Finalidade do GENESIS

O GENESIS Rust produz registros sintéticos longitudinais para testar a infraestrutura quando o uso de dados acadêmicos reais ainda não está autorizado ou disponível. Os estudantes, matrículas, disciplinas e períodos são entidades de uma população simulada. O gerador permite testes de carga, consistência e validação de contratos; não estabelece que suas distribuições reproduzam automaticamente as de escolas brasileiras.

2. Caminho de proveniência

O fluxo analisado parte de dados GENESIS, passa por transformações temporais MAPA, produz Parquet por corte e termina em relatórios JSON versionados. O identificador do manifesto de features do benchmark 5K é **ec863d9f267564e27adf1a701f88951cf064af744eb2452708f120c22d947f23**. O SHA-256 registra identidade de conteúdo, não garante realismo estatístico, ausência de vieses ou integridade de todo o ambiente externo.



Figura 1. Cadeia conceitual de proveniência entre gerador, atributos e evidências.
Fonte: elaboração própria, com base no relatório sintético MAPA 5K (schema epa.mapa.statistical_evaluation.v1).

3. Escala e significado dos registros

Na execução 5K foram escolhidos 5.000 estudantes da população sintética de origem. Cada divisão reuniu 3.750 estudantes no treino e 1.250 no teste; por corte e seed, 202.500 observações de treino e 67.500 de teste. O total de linhas é maior que o de estudantes por causa de disciplinas e anos letivos repetidos.

Uma contagem elevada de linhas melhora a cobertura de cenários de software, mas **não** autoriza tratá-las como 270.000 alunos independentes. A separação e o cálculo da incerteza devem respeitar a hierarquia dos dados.

4. Seeds e determinismo

Seed é uma semente numérica que inicializa decisões pseudoaleatórias. O relatório fixa a seed de seleção 20261029 e três seeds de divisão: 20261029, 20261030, 20261031. Cada seed de divisão produz um holdout distinto. Isso permite comparar sensibilidade à partição, mas os holdouts continuam compartilhando a mesma população sintética.

5. Riscos metodológicos

Viés de simulação: diferenças entre regras geradas e comportamento real. **Circularidade do alvo:** risco de os critérios do gerador, usados para produzir aprovação/reprovação, serem semelhantes às regras que o estimador aprende. **Mudança de domínio:** alterações nas distribuições de notas, frequência e gestão escolar, não observadas neste benchmark.

Para demonstrar generalização fora da população atual seria necessário treinar com uma população GENESIS e avaliar em outra, ou, preferencialmente, validar com dados reais autorizados. Essa etapa permanece fora do escopo congelado.

6. Reprodutibilidade prática

Um relatório reproduzível deve fixar código/commit, versões de dependências, identificador do manifesto, regras de seleção de alunos, seeds, recursos computacionais e esquema JSON. O benchmark local forneceu duração externa de **445,2471287 segundos**, mas não registrou pico de memória RSS.

7. Termos para glossário

Parquet: formato colunar usado em datasets analíticos. **Manifesto:** registro de conteúdo e parâmetros que descrevem os artefatos. **SHA-256:** resumo criptográfico de 256 bits usado para identificar bytes. **Proveniência:** histórico da origem e das transformações de dados. **População sintética:** conjunto gerado por regras computacionais, não coleta escolar observacional.

Referências e rastreabilidade

[1] Gneiting, T.; Raftery, A. E. (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, 102(477), 359–378. DOI: 10.1198/016214506000001437. [2] Efron, B.; Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman & Hall. [3] scikit-learn developers. User Guide: Model evaluation, Probability calibration, GroupShuffleSplit, MLPClassifier. https://scikit-learn.org/stable/user_guide.html (consulta metodológica; versão efetiva do ambiente deve ser registrada). [4] EduPredict Analytics. Relatório técnico interno MAPA 5K, schema epa.mapa.statistical_evaluation.v1; manifesto ec863d9f267564e27adf1a701f88951cf064af744eb2452708f120c22d947f23; população sintética e três seeds, novembro de 2026.