C03 — MAPA temporal e prevenção de vazamento

EduPredict Analytics (EPA) · Cadernos de Pesquisa · TGI II

Carlos Eduardo Franco Gabriel · Miguel Ferreira Palmieri Souza Rocha

Universidade Cruzeiro do Sul — Ciência da Computação — São Paulo, Brasil

Orientador: Prof. Me. João Roberto Ursino da Cruz

Versão: 0.3 (congelamento sintético de 12 nov. 2026)

Status: SYNTHETIC_NOT_EMPIRICALLY_VALIDATED

Resumo. Demonstrar por que N1, N2 e N3 só podem utilizar informações disponíveis no momento da predição. O documento distingue resultados medidos, explicação técnica e inferências limitadas à população sintética GENESIS.

Palavras-chave. EduPredict Analytics; avaliação temporal; dados sintéticos; rastreabilidade; aprendizado de máquina.

1. Predição point-in-time

Um teste antecipado só é honesto quando a representação do estudante é construída **como seria no instante da decisão**. O MAPA exporta snapshots para N1, N2 e N3. Em N1 não se pode usar notas de N2, N3 ou N4; em N2 não se pode usar N3/N4; e em N3 o último período continua futuro.



Figura 1. Sequência conceitual de disponibilidade temporal; as setas não representam a inclusão de dados futuros.
Fonte: elaboração própria, com base no relatório sintético MAPA 5K (schema epa.mapa.statistical_evaluation.v1).

2. As onze features observadas

As entradas são current_mean_grade, current_attendance_rate, current_absences, current_unexcused_absences, current_sessions, prior_mean_grade, prior_attendance_rate, prior_absences, prior_unexcused_absences, prior_term_count e prior_years_observed. Em português: média atual, taxa de frequência atual, faltas atuais, faltas não justificadas atuais, sessões atuais e seis indicadores de histórico anterior.

O rótulo target_final_subject_outcome aparece no dataset de treinamento para supervisão, mas **não** deve ser fornecido como entrada. Atributos históricos devem referir-se a períodos anteriores, não a informações coletadas depois do corte.

3. Data leakage: quatro caminhos de erro

Vazamento temporal: calcular médias com avaliações posteriores. **Vazamento de alvo:** usar campo que determina diretamente o resultado final. **Vazamento entre alunos:** deixar linhas do mesmo aluno em treino e teste. **Vazamento de pré-processamento:** calcular normalização ou imputação com todos os dados, inclusive o teste.

O protocolo usa agrupamento por estudante e pipelines de pré-processamento ajustados somente em treino. Essas salvaguardas mitigam riscos específicos; não provam ausência absoluta de leakage em todas as transformações

upstream.

4. Auditabilidade

Para cada corte deve ser possível indicar quais colunas foram lidas, qual manifesto autorizou seu uso e quantas observações entraram em treino/teste. A mesma lógica deve ser aplicada a validações futuras de múltiplas populações.

5. Evidência temporal no benchmark

O aumento do macro-F1 de N1 para N3 é compatível com a hipótese de que observações acadêmicas adicionais tornam o desfecho mais previsível dentro do gerador. Porém, como os alvos são produzidos sinteticamente, não se pode descartar que o padrão reflita principalmente as regras do simulador.

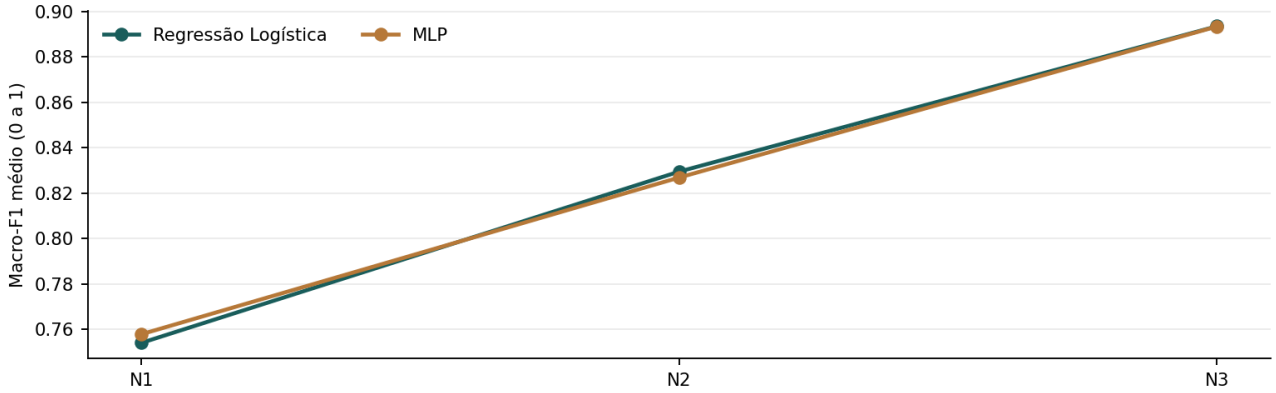


Figura 2. Evolução da métrica de classificação nos cortes avaliados.
Fonte: elaboração própria, com base no relatório sintético MAPA 5K (schema epa.mapa.statistical_evaluation.v1).

6. Exemplo didático

Considere uma disciplina com N1 = 5,0 e N2 = 7,0. Para uma predição feita em N1, a média 6,0 seria informação proibida: N2 ainda não ocorreu. Mesmo que o modelo pareça melhorar com essa variável, o experimento teria invalidado o caráter antecipatório.

7. Termos para glossário

Snapshot: registro dos atributos disponíveis num instante. **Point-in-time:** regra que impede usar informação posterior à predição. **Data leakage:** vazamento de informação indevida para treinamento ou teste. **Imputação:** preenchimento controlado de valores ausentes. **Pipeline:** cadeia de transformações reproduzível.

Referências e rastreabilidade

[1] Gneiting, T.; Raftery, A. E. (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, 102(477), 359–378. DOI: 10.1198/016214506000001437. [2] Efron, B.; Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman & Hall. [3] scikit-learn developers. User Guide: Model evaluation, Probability calibration, GroupShuffleSplit, MLPClassifier. https://scikit-learn.org/stable/user_guide.html (consulta metodológica; versão efetiva do ambiente deve ser registrada). [4] EduPredict Analytics. Relatório técnico interno MAPA 5K, schema epa.mapa.statistical_evaluation.v1; manifesto ec863d9f267564e27adf1a701f88951cf064af744eb2452708f120c22d947f23; população sintética e três seeds, novembro de 2026.