C04 — Particionamento, baselines e métricas

EduPredict Analytics (EPA) · Cadernos de Pesquisa · TGI II

Carlos Eduardo Franco Gabriel · Miguel Ferreira Palmieri Souza Rocha

Universidade Cruzeiro do Sul — Ciência da Computação — São Paulo, Brasil

Orientador: Prof. Me. João Roberto Ursino da Cruz

Versão: 0.3 (congelamento sintético de 12 nov. 2026)

Status: SYNTHETIC_NOT_EMPIRICALLY_VALIDATED

Resumo. Formalizar como a avaliação é feita e como interpretar métricas de três classes sem depender apenas da acurácia. O documento distingue resultados medidos, explicação técnica e inferências limitadas à população sintética GENESIS.

Palavras-chave. EduPredict Analytics; avaliação temporal; dados sintéticos; rastreabilidade; aprendizado de máquina.

1. Unidade independente e split

O experimento 5K dividiu 5.000 estudantes em grupos com 75% para treino e 25% para teste. **Todas as linhas de um mesmo estudante permanecem no mesmo lado**. Em uma divisão resultam 3.750 estudantes em treino e 1.250 em teste, com diversas observações disciplinares para cada aluno.

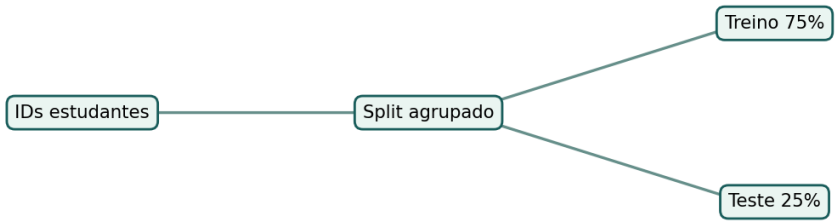


Figura 1. Separação agrupada por estudante: disciplinas do mesmo aluno não atravessam o split.
Fonte: elaboração própria, com base no relatório sintético MAPA 5K (schema epa.mapa.statistical_evaluation.v1).

2. A matriz de confusão

Para cada uma das três classes, a matriz relaciona resultado observado (linha) e predito (coluna). A diagonal contabiliza acertos; os demais elementos identificam confusões. Por exemplo, classificar reprovado como recuperação é um erro que pode ser pedagogicamente relevante mesmo quando o número total de acertos permanece alto.

3. Precisão, recall e F1

Para a classe c, define-se TP como verdadeiro positivo, FP como falso positivo e FN como falso negativo. **Precisão = TP/(TP+FP)**. **Recall = TP/(TP+FN)**. **F1 = 2 × precisão × recall/(precisão+recall)**. O **macro-F1** é a média aritmética dos F1 das três classes; a **balanced accuracy** é a média dos recalls das classes. Denominadores nulos precisam ter regra explícita de tratamento.

Acurácia é o total de previsões corretas dividido pelo total de previsões. Uma estratégia que prevê sempre a classe predominante pode ter acurácia aparentemente aceitável enquanto falha em detectar reprovação. Por isso são indispensáveis macro-F1, recall por classe e baseline de maioria.

4. Métricas probabilísticas

O **log loss** penaliza probabilidades incorretas com grande confiança. O **Brier multiclasse** soma os quadrados das diferenças entre probabilidade prevista e indicador da classe verdadeira. Ambas são medidas probabilísticas cujo menor valor representa melhor pontuação, mas não demonstram isoladamente calibração perfeita.

5. Protocolos comparáveis

Comparações entre estimadores devem usar as mesmas divisões, cutoffs, classes e regras de preprocessamento. As três seeds geram três holdouts na mesma população; médias entre elas são descritivas, não nove ensaios independentes.

6. Resultado empírico sintético do 5K

O macro-F1 médio passou de aproximadamente 0,75 no N1 para 0,89 no N3 em ambos os modelos. O recall de reprovação no N1 ficou próximo de 50%, evidenciando que desempenho agregado não equivale a cobertura satisfatória da classe crítica.

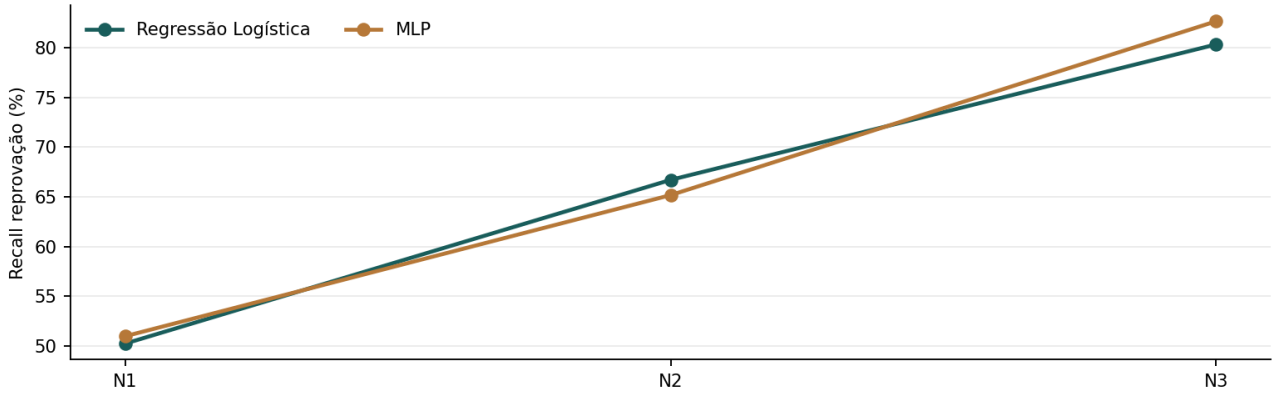


Figura 2. Recall médio da classe reprovado nos três cortes.
Fonte: elaboração própria, com base no relatório sintético MAPA 5K (schema epa.mapa.statistical_evaluation.v1).

7. Termos para glossário

TP/FP/FN: contagens de acertos positivos, alarmes indevidos e casos perdidos. **Precisão:** fração de predições positivas corretas. **Recall/sensibilidade:** fração dos casos reais de uma classe recuperada pelo classificador. **Balanced accuracy:** recall médio entre classes. **Baseline:** referência simples a superar.

Referências e rastreabilidade

[1] Gneiting, T.; Raftery, A. E. (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, 102(477), 359–378. DOI: 10.1198/016214506000001437. [2] Efron, B.; Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman & Hall. [3] scikit-learn developers. User Guide: Model evaluation, Probability calibration, GroupShuffleSplit, MLPClassifier. https://scikit-learn.org/stable/user_guide.html (consulta metodológica; versão efetiva do ambiente deve ser registrada). [4] EduPredict Analytics. Relatório técnico interno MAPA 5K, schema epa.mapa.statistical_evaluation.v1; manifesto ec863d9f267564e27adf1a701f88951cf064af744eb2452708f120c22d947f23; população sintética e três seeds, novembro de 2026.