C05 — Classificadores, arquitetura e treinamento

EduPredict Analytics (EPA) · Cadernos de Pesquisa · TGI II

Carlos Eduardo Franco Gabriel · Miguel Ferreira Palmieri Souza Rocha

Universidade Cruzeiro do Sul — Ciência da Computação — São Paulo, Brasil

Orientador: Prof. Me. João Roberto Ursino da Cruz

Versão: 0.3 (congelamento sintético de 12 nov. 2026)

Status: SYNTHETIC_NOT_EMPIRICALLY_VALIDATED

Resumo. Descrever Logistic Regression, Random Forest e MLP, incluindo o escopo efetivamente treinado no avaliador 5K. O documento distingue resultados medidos, explicação técnica e inferências limitadas à população sintética GENESIS.

Palavras-chave. EduPredict Analytics; avaliação temporal; dados sintéticos; rastreabilidade; aprendizado de máquina.

1. Família de modelos

O pipeline nativo suporta baseline por maioria, Regressão Logística, Random Forest e MLP. No **avaliador estatístico final 5K**, somente **Regressão Logística e MLP** foram selecionados; as demais famílias pertencem ao benchmark exploratório anterior e não devem ser inseridas em tabelas estatísticas 5K como se tivessem sido retreinadas.

2. Regressão Logística multiclasse

Apesar do nome, é um classificador probabilístico. Com um vetor de atributos x, estima escores lineares $z_c = w_c \cdot x + b_c$ e os converte em probabilidades por função softmax. Os parâmetros são ajustados para reduzir perda de classificação probabilística. A linearidade facilita reprodutibilidade e economia computacional, mas não garante interpretação causal dos coeficientes.

3. Perceptron multicamadas (MLP)

A arquitetura documentada para esta execução possui **11 entradas, duas camadas ocultas de 32 e 16 unidades e três saídas**. Cada neurônio calcula combinação ponderada seguida de transformação não linear. A previsão final é uma distribuição de probabilidades sobre as três classes. O gráfico apresenta a **topologia configurada**, não valores dos pesos nem ativação monitorada durante as épocas.

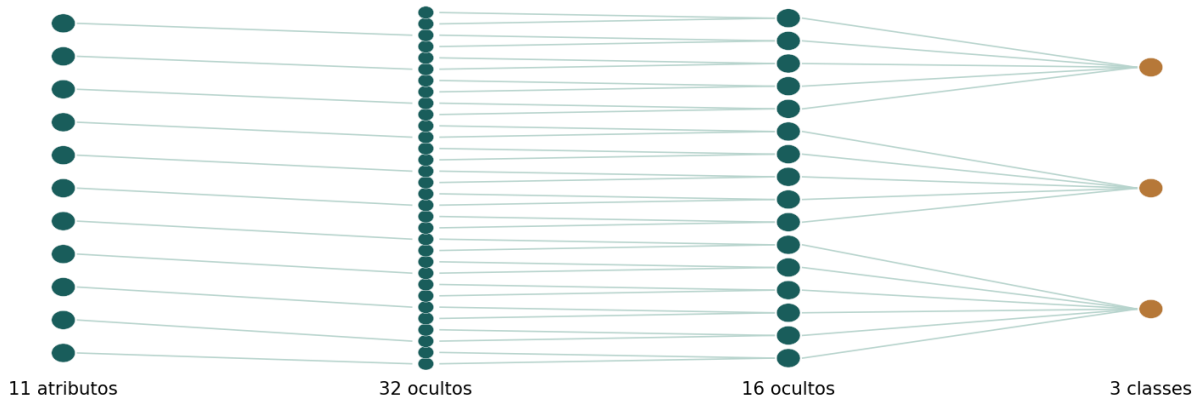


Figura 1. Diagrama representativo da arquitetura 11–32–16–3 do MLP. Conexões resumidas para legibilidade.
Fonte: elaboração própria, com base no relatório sintético MAPA 5K (schema epa.mapa.statistical_evaluation.v1).

4. Random Forest como referência arquitetural

A Random Forest combina diversas árvores de decisão, cada uma com divisões sucessivas de atributos e limiares. A agregação das árvores busca reduzir variabilidade em relação a uma única árvore. O desenho é **didático**, não a estrutura aprendida por um estimador 5K.

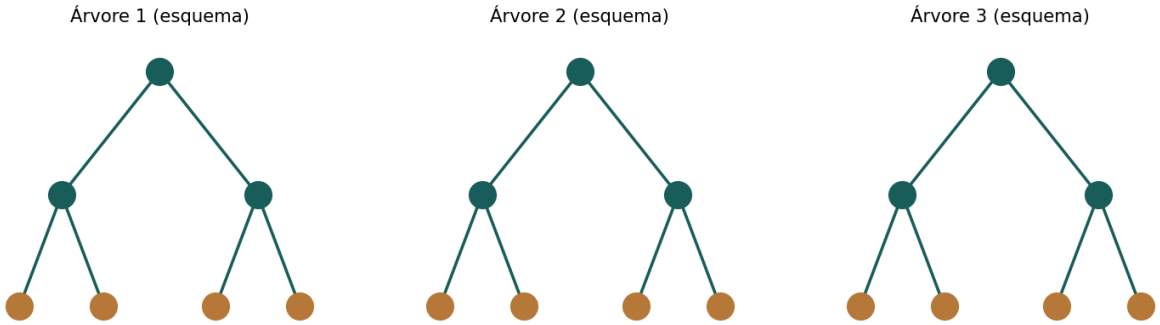


Figura 2. Ilustração esquemática de uma floresta de árvores, sem nós ou thresholds reais.
Fonte: elaboração própria, com base no relatório sintético MAPA 5K (schema epa.mapa.statistical_evaluation.v1).

5. Comparação numérica 5K

A Regressão Logística apresentou macro-F1 médio de 0,7540/0,8294/0,8934 (N1/N2/N3); o MLP apresentou 0,7578/0,8268/0,8933. A vantagem alterna entre cortes e os intervalos pareados não definem um vencedor geral. Dado o ganho modesto do MLP, o custo de ajuste precisa compor o critério de seleção.

6. Controle de treinamento

As seeds, limites amostrais, ordem das classes e versões das bibliotecas devem ser registradas. A escolha de hiperparâmetros não deve usar repetidamente o teste final. Para futuros ajustes de arquitetura ou limiar, é necessário separar validação independente agrupada por estudante.

7. Termos para glossário

MLP: rede neural feedforward de várias camadas. **Neurônio artificial:** operação de soma ponderada seguida de ativação. **Peso:** coeficiente aprendido. **Softmax:** função de normalização de escores em probabilidades. **Random Forest:** conjunto de árvores. **Hiperparâmetro:** configuração escolhida antes do ajuste.

Referências e rastreabilidade

[1] Gneiting, T.; Raftery, A. E. (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, 102(477), 359–378. DOI: 10.1198/016214506000001437. [2] Efron, B.; Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman & Hall. [3] scikit-learn developers. User Guide: Model evaluation, Probability calibration, GroupShuffleSplit, MLPClassifier. https://scikit-learn.org/stable/user_guide.html (consulta metodológica; versão efetiva do ambiente deve ser registrada). [4] EduPredict Analytics. Relatório técnico interno MAPA 5K, schema epa.mapa.statistical_evaluation.v1; manifesto ec863d9f267564e27adf1a701f88951cf064af744eb2452708f120c22d947f23; população sintética e três seeds, novembro de 2026.