C07 — Calibração, log loss e pontuações probabilísticas

EduPredict Analytics (EPA) · Cadernos de Pesquisa · TGI II

Carlos Eduardo Franco Gabriel · Miguel Ferreira Palmieri Souza Rocha

Universidade Cruzeiro do Sul — Ciência da Computação — São Paulo, Brasil

Orientador: Prof. Me. João Roberto Ursino da Cruz

Versão: 0.3 (congelamento sintético de 12 nov. 2026)

Status: SYNTHETIC_NOT_EMPIRICALLY_VALIDATED

Resumo. Contextualizar a confiabilidade das probabilidades, diferenciando medidas de pontuação de calibração demonstrada. O documento distingue resultados medidos, explicação técnica e inferências limitadas à população sintética GENESIS.

Palavras-chave. EduPredict Analytics; avaliação temporal; dados sintéticos; rastreabilidade; aprendizado de máquina.

1. Probabilidade como saída de decisão

Um classificador pode acertar a classe mais provável e ainda informar probabilidades exageradas ou conservadoras. Para aplicações educacionais, uma previsão de 0,85 para reprovação precisa ser interpretada com cuidado: se os eventos previstos com esse grau de confiança ocorrerem apenas 0,50 das vezes, a probabilidade está mal calibrada.

2. Log loss e Brier

O **log loss** cresce muito quando um modelo atribui probabilidade pequena ao resultado que efetivamente ocorreu. O **Brier multiclasse** é uma pontuação quadrática entre probabilidades e vetores indicadores das classes. Ambas são *proper scoring rules*, úteis para avaliar qualidade global das probabilidades.

No benchmark 5K, log loss médio N1→N3: Regressão Logística 0,3912→0,1759; MLP 0,3827→0,1769. A diminuição é consistente com previsões probabilísticas melhores em cortes tardios, mas não prova calibração por subgrupos ou aplicação real.

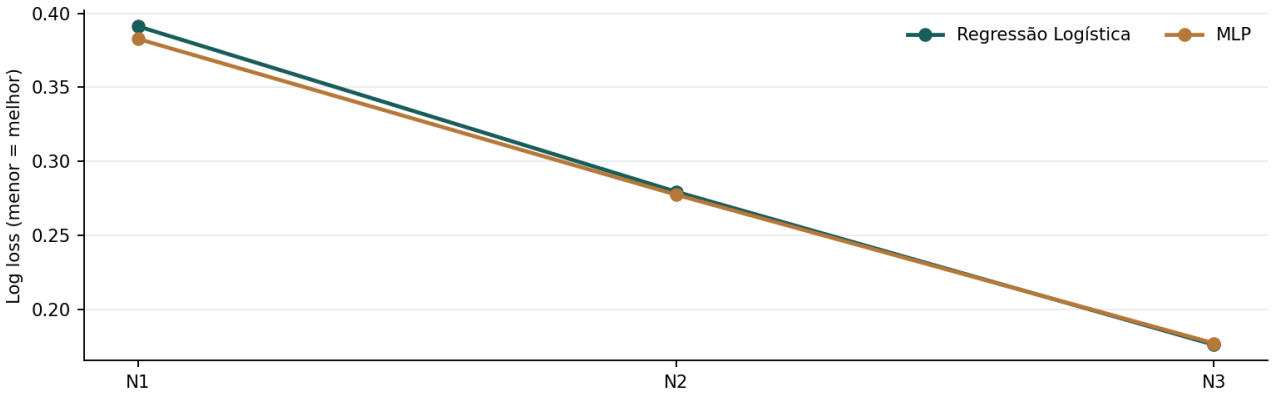


Figura 1. Log loss médio das três divisões do experimento 5K.
Fonte: elaboração própria, com base no relatório sintético MAPA 5K (schema epa.mapa.statistical_evaluation.v1).

3. Confiabilidade descritiva

A análise produz **reliability bins**: agrupa probabilidades previstas em dez faixas e compara probabilidade média com frequência observada. O procedimento é calculado para a classe mais provável (top-label) e em abordagem um-contra-o-resto para cada classe. **ECE**, erro esperado de calibração, resume diferenças absolutas ponderadas pelos tamanhos das faixas.

A ECE depende do número e da ocupação dos bins; valores baixos podem ocultar divergências em faixas raras ou grupos minoritários. Ela não equivale a calibrar o classificador. **Nenhum recalibrador foi ajustado** neste ensaio, e fazê-lo sobre o conjunto final de teste criaria leakage.

4. Classe minoritária

Reprovação representa cerca de 5%–6% das observações nos holdouts 5K. Uma ECE baixa pode ser dominada pelas numerosas previsões de probabilidade próxima a zero; examinar faixas com suporte pequeno e erros falsos-negativos ainda é obrigatório.

5. Protocolo de calibração futura

Uma evolução adequada deve separar treino, validação agrupada para calibrador/limiares e teste final intocado. Métodos como sigmoid/Platt ou isotonic podem ser comparados sob essa separação, mas não estão presentes no conjunto congelado.

6. Termos para glossário

Calibração: correspondência entre confiança prevista e frequência observada. **Reliability diagram:** gráfico de confiança versus frequência. **ECE:** resumo dependente de faixas do erro de calibração. **Log loss:** penalidade logarítmica probabilística. **Brier score:** perda quadrática probabilística. **One-vs-rest:** análise de uma classe contra todas as demais.

Referências e rastreabilidade

[1] Gneiting, T.; Raftery, A. E. (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, 102(477), 359–378. DOI: 10.1198/016214506000001437. [2] Efron, B.; Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman & Hall. [3] scikit-learn developers. User Guide: Model evaluation, Probability calibration, GroupShuffleSplit, MLPClassifier. https://scikit-learn.org/stable/user_guide.html (consulta metodológica; versão efetiva do ambiente deve ser registrada). [4] EduPredict Analytics. Relatório técnico interno MAPA 5K, schema epa.mapa.statistical_evaluation.v1; manifesto ec863d9f267564e27adf1a701f88951cf064af744eb2452708f120c22d947f23; população sintética e três seeds, novembro de 2026.