C08 — Resultados comparativos e análise de erros

EduPredict Analytics (EPA) · Cadernos de Pesquisa · TGI II

Carlos Eduardo Franco Gabriel · Miguel Ferreira Palmieri Souza Rocha

Universidade Cruzeiro do Sul — Ciência da Computação — São Paulo, Brasil

Orientador: Prof. Me. João Roberto Ursino da Cruz

Versão: 0.3 (congelamento sintético de 12 nov. 2026)

Status: SYNTHETIC_NOT_EMPIRICALLY_VALIDATED

Resumo. Consolidar os resultados sintéticos 5K, sua evolução temporal e o problema dos falsos negativos de reprovação. O documento distingue resultados medidos, explicação técnica e inferências limitadas à população sintética GENESIS.

Palavras-chave. EduPredict Analytics; avaliação temporal; dados sintéticos; rastreabilidade; aprendizado de máquina.

1. Matriz de resultados do experimento final

O ensaio 5K utilizou 5.000 estudantes sintéticos, três seeds de split e cortes N1/N2/N3. As médias aritméticas de métricas são descritivas e não são intervalos de confiança entre três populações.

Corte	Modelo	Acurácia	Macro-F1	Recall reprovação	Log loss
N1	Logística	0,8259	0,7540	0,5025	0,3912
N1	MLP	0,8291	0,7578	0,5099	0,3827
N2	Logística	0,8772	0,8294	0,6671	0,2794
N2	MLP	0,8767	0,8268	0,6518	0,2774
N3	Logística	0,9224	0,8934	0,8033	0,1759
N3	MLP	0,9217	0,8933	0,8266	0,1769

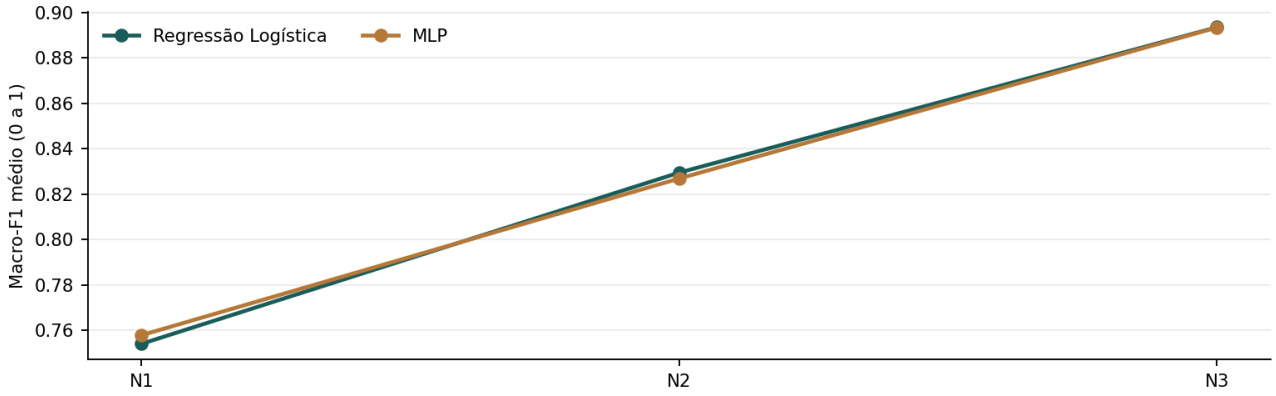


Figura 1. Comparação do macro-F1 médio por corte.
Fonte: elaboração própria, com base no relatório sintético MAPA 5K (schema epa.mapa.statistical_evaluation.v1).

2. A dificuldade da predição antecipada

O maior erro qualitativo é a identificação insuficiente de reprovação no primeiro corte. O recall de reprovado gira em torno de 50% em N1, melhora para 65%–67% em N2 e atinge cerca de 80%–83% em N3. O modelo precisa equilibrar antecedência e informação disponível: prever cedo é mais útil para intervir, mas é estatisticamente mais incerto.

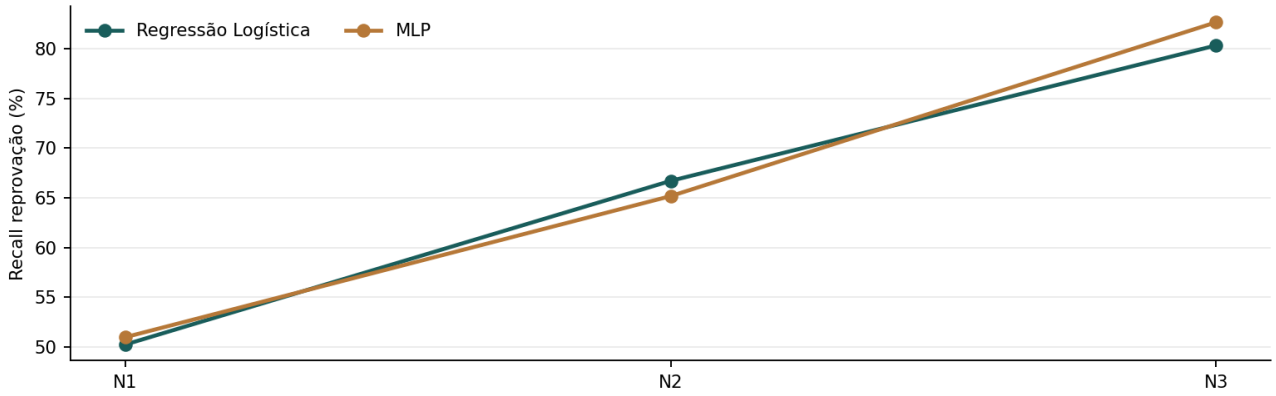


Figura 2. Evolução do recall de reprovação nos cortes.
Fonte: elaboração própria, com base no relatório sintético MAPA 5K (schema epa.mapa.statistical_evaluation.v1).

3. Por que não basta a acurácia

Aprovação é frequente; um classificador pode acertar muitos aprovados e ainda negligenciar reprovados. Macro-F1 fornece peso igual às três classes. Recall de reprovação esclarece a fração dos casos críticos identificados; isoladamente, porém, não informa quantos alertas falsos foram criados. A inspeção conjunta de precisão, recall e matriz de confusão é essencial.

4. Alternância entre modelos

A MLP apresenta macro-F1 ligeiramente maior em N1; a Logística tem pequena vantagem em N2 e praticamente empata no N3. A análise de intervalos pareados não sustenta declarar um vencedor universal. Recomenda-se manter a Logística como referência de baixo custo e a MLP como comparador de capacidade não linear.

5. Resultados não demonstrados

O experimento não mediu efetividade de intervenções, evasão real, impacto em professores, generalização entre escolas ou desempenho em grupos demográficos. Não atribuir esses efeitos aos resultados apresentados.

6. Termos para glossário

Falso negativo: caso real de reprovação não identificado. **Falso positivo:** aviso de reprovação quando o desfecho é outro. **Trade-off:** compromisso entre objetivos em tensão, como antecedência e sensibilidade. **Support:** número de observações reais de cada classe.

Referências e rastreabilidade

[1] Gneiting, T.; Raftery, A. E. (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, 102(477), 359–378. DOI: 10.1198/016214506000001437. [2] Efron, B.; Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman & Hall. [3] scikit-learn developers. User Guide: Model evaluation, Probability calibration, GroupShuffleSplit, MLPClassifier. https://scikit-learn.org/stable/user_guide.html (consulta metodológica; versão efetiva do ambiente deve ser registrada). [4] EduPredict Analytics. Relatório técnico interno MAPA 5K, schema epa.mapa.statistical_evaluation.v1; manifesto ec863d9f267564e27adf1a701f88951cf064af744eb2452708f120c22d947f23; população sintética e três seeds, novembro de 2026.