C09 — Escalabilidade, custo e reprodutibilidade

EduPredict Analytics (EPA) · Cadernos de Pesquisa · TGI II

Carlos Eduardo Franco Gabriel · Miguel Ferreira Palmieri Souza Rocha

Universidade Cruzeiro do Sul — Ciência da Computação — São Paulo, Brasil

Orientador: Prof. Me. João Roberto Ursino da Cruz

Versão: 0.3 (congelamento sintético de 12 nov. 2026)

Status: SYNTHETIC_NOT_EMPIRICALLY_VALIDATED

Resumo. Apresentar custo do benchmark 5K e diferenciar duração total de tempo de ajuste dos modelos. O documento distingue resultados medidos, explicação técnica e inferências limitadas à população sintética GENESIS.

Palavras-chave. EduPredict Analytics; avaliação temporal; dados sintéticos; rastreabilidade; aprendizado de máquina.

1. Estrutura computacional do benchmark

O teste 5K utiliza 18 ajustes: 3 cutoffs × 3 seeds × 2 algoritmos. A cada combinação há seleção de grupos, leitura dos atributos, ajuste, previsão, cálculo de métricas e bootstrap com 200 reamostragens por grupo de estudantes.

2. Tempo observado

O comando externo PowerShell Measure-Command registrou **445,2471287 segundos** (cerca de 7 min e 25 s) para todo o processo. Essa medida envolve inicialização do Python, carga de dados, transformação, ajuste, predição, intervalos e gravação do JSON. Não constitui média de múltiplas execuções com controle de ambiente.

Os ajustes individuais apresentaram médias em segundos: Logística N1=2,44, N2=1,65, N3=1,89; MLP N1=32,10, N2=30,18, N3=31,14. O custo do MLP foi substancialmente maior que o linear.

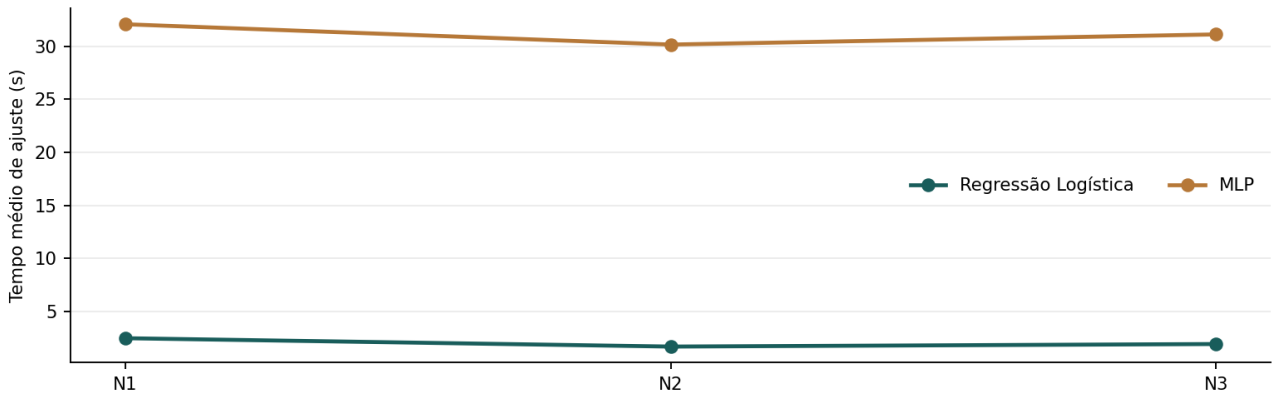


Figura 1. Tempo de ajuste por modelo e corte (média de três seeds, 5K).
Fonte: elaboração própria, com base no relatório sintético MAPA 5K (schema epa.mapa.statistical_evaluation.v1).

3. Escala ≠ generalização

Confrontos preliminares com 500 e 2.000 estudantes apontaram estabilidade do macro-F1, mas, para um quadro comparativo definitivo, os JSONs dessas execuções devem integrar o conjunto versionado de evidências e ser associados aos respectivos hashes. O congelamento deste volume privilegia o relatório 5K, disponibilizado e verificado.

4. Perfil de memória e processamento

O avaliador usa etapas em memória e leitura analítica do Parquet. **Não existe medição de pico RSS no relatório 5K.** Portanto, é inadequado afirmar consumo máximo de RAM ou eficiência out-of-core. Fit time não inclui bootstrap nem E/S, e o total de execução não equivale exclusivamente ao tempo de treinamento.

5. Manifestos e rastreabilidade

O hash do manifesto de entrada é ec863d9f267564e27adf1a701f88951cf064af744eb2452708f120c22d947f23. O registro documental aponta SHA-256 do JSON final 903298722b6b44cd9f955ee4ece73419781c3933deea27f1393ad84846f37836. Um hash só é útil se for verificado contra os mesmos bytes e acompanhado de identificação do código e das dependências.

6. Critério de congelamento

Os dados e resultados podem ser congelados para escrita como **ensaio sintético controlado**. Novas versões devem criar novos identificadores, jamais sobrescrever artefatos e conclusões anteriores. A reprodução completa em outra máquina depende da publicação de dependências e geradores compatíveis.

7. Termos para glossário

RSS: memória física residente em um processo. **Fit time:** tempo estrito de ajuste do estimador. **Wall time:** tempo transcorrido de ponta a ponta. **Out-of-core:** processamento sem manter todo o conjunto em RAM. **Escalabilidade:** evolução do custo computacional com tamanho do problema.

Referências e rastreabilidade

[1] Gneiting, T.; Raftery, A. E. (2007). Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, 102(477), 359–378. DOI: 10.1198/016214506000001437. [2] Efron, B.; Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman & Hall. [3] scikit-learn developers. User Guide: Model evaluation, Probability calibration, GroupShuffleSplit, MLPClassifier. https://scikit-learn.org/stable/user_guide.html (consulta metodológica; versão efetiva do ambiente deve ser registrada). [4] EduPredict Analytics. Relatório técnico interno MAPA 5K, schema epa.mapa.statistical_evaluation.v1; manifesto ec863d9f267564e27adf1a701f88951cf064af744eb2452708f120c22d947f23; população sintética e três seeds, novembro de 2026.