Glossário técnico — EduPredict Analytics

Acurácia: proporção de todas as observações corretamente classificadas. Não garante bom desempenho em classes raras.

Baseline: modelo simples de referência, por exemplo, prever sempre a classe majoritária.

Balanced accuracy: média do recall de cada classe; evita que classes muito frequentes dominem o resumo.

Bootstrap: reamostragem com reposição usada para caracterizar variabilidade de estatísticas sob suposições explícitas.

Bootstrap por cluster: sorteia grupos inteiros correlacionados; no EPA, estudantes e todos seus registros de teste.

Brier multiclasse: média da soma dos quadrados da diferença entre probabilidades previstas e indicadores das classes reais. Menor = melhor.

Calibração: correspondência entre probabilidade prevista e frequência observada em conjuntos comparáveis.

Classe minoritária: classe que ocorre menos frequentemente, como reprovação neste conjunto sintético.

Data leakage: uso indevido de informação futura, do alvo ou do conjunto de teste em preparação, ajuste ou seleção.

ECE (Expected Calibration Error): desvio médio ponderado por faixas de probabilidade; sensível ao binning e às frequências das classes.

Feature (atributo): variável de entrada, como frequência observada até o corte.

Falso negativo (FN): observação da classe de interesse classificada como outra classe; reprovação não detectada é exemplo relevante.

Falso positivo (FP): observação apontada como da classe de interesse mas pertencente a outra classe.

Fit time: tempo de ajuste do algoritmo, excluindo leitura, transformações e análise posterior, se medido assim.

F1-score: média harmônica entre precisão e recall para uma classe: 2PR/(P+R).

Holdout: subconjunto reservado para avaliar o modelo fora do ajuste.

Hiperparâmetro: configuração fixada antes do ajuste, como número de neurônios.

IC 95%: intervalo produzido por método estatístico cuja interpretação depende do modelo de amostragem; não fornece probabilidade frequentista do parâmetro fixo.

Log loss: penalidade probabilística logarítmica que pune confiança alta em respostas erradas.

Macro-F1: média aritmética dos F1 das classes, concedendo o mesmo peso a cada classe; útil sob desbalanceamento.

Manifesto: arquivo que descreve identidade, esquema, proveniência e artefatos de um dataset.

MLP (Multilayer Perceptron): rede neural de camadas densas para aprender relações não lineares entre atributos e classes.

One-vs-rest: avaliação da classe especificada contra a união de todas as outras.

Parquet: armazenamento colunar eficiente para processamento analítico.

Point-in-time: restrição temporal que permite somente dados conhecidos no momento da predição.

População sintética: dados gerados programaticamente; não substituem amostras escolares observadas.

Precisão (precision): TP/(TP+FP), fração dos alertas positivos que estavam corretos.

Recall (sensibilidade): TP/(TP+FN), fração de casos verdadeiros da classe que o modelo recuperou. Recall 50% de reprovação significa que cerca de metade das observações realmente reprovadas foi detectada.

Reliability diagram: visualização de probabilidades médias previstas versus frequência empírica do evento por faixas.

RSS (Resident Set Size): memória física residente em processo, diferente da memória virtual reservada.

Seed: valor inicial que torna reproduzíveis sorteios pseudoaleatórios num dado ambiente.

SHA-256: hash criptográfico usado para identificar os bytes do manifesto; não prova validade científica dos dados.

Snapshot temporal: visão dos atributos no momento de corte N1, N2 ou N3.

Split agrupado: separação de treino e teste por identificador de estudante, evitando linhas do mesmo aluno em ambos.

Suporte (support): número de observações reais pertencentes a determinada classe.

Target (alvo): variável que o classificador tenta prever, neste caso desfecho final da disciplina.

Trade-off: compromisso entre objetivos, como antecipação do alerta e precisão da identificação.

Wall time: duração real de todo o comando, incluindo carregamento, ajuste, avaliação e gravação.